



Progetto di Machine Learning: Predizione delle Malattie Cardiache

RELAZIONE TECNICA DI PROGETTO

Carlomagno Elena, Cervino Rosaria

Machine Learning – A.A. 2025/2026

31/01/2026

1. Lo Scenario e il Task

Le malattie cardiovascolari rappresentano oggi una delle principali cause di mortalità a livello globale. La diagnosi precoce è fondamentale per ridurre i rischi di complicazioni gravi o decessi legati all'insufficienza cardiaca. Tuttavia, la valutazione clinica tradizionale può essere complessa a causa della moltitudine di fattori di rischio che interagiscono tra loro, come l'età, i livelli di colesterolo, la pressione sanguigna e i segnali elettrocardiografici.

In questo scenario, gli strumenti di **Computer-Aided Diagnosis (CAD)** basati sul Machine Learning offrono un supporto prezioso ai medici, permettendo di analizzare grandi volumi di dati storici per identificare pattern non immediatamente visibili all'occhio umano.

Definizione del Problema: Il problema analizzato consiste nella necessità di classificare i pazienti in base alla probabilità di essere affetti da una patologia cardiaca. Partendo da un set di parametri clinici ottenuti tramite esami di routine (es. esami del sangue, ECG a riposo e sotto sforzo), si vuole determinare se un individuo appartiene alla classe "Sano" o alla classe "Affetto da malattia cardiaca".

Dal punto di vista computazionale, il task è definito come un problema di **Apprendimento Supervisionato (Supervised Learning)**, specificamente un task di **Classificazione Binaria**.

Il modello riceve in input un vettore di caratteristiche (feature) e restituisce in output una variabile target discreta:

- **0 (Normal):** Paziente che non presenta patologie cardiache.
- **1 (Heart Disease):** Paziente con presenza confermata di patologia cardiaca.

L'obiettivo finale è massimizzare la capacità predittiva del modello, ponendo particolare attenzione alla riduzione dei falsi negativi, poiché una mancata diagnosi in ambito medico comporta rischi estremamente elevati per la salute del paziente.

2. Dataset e le sue caratteristiche

Il dataset impiegato per lo sviluppo del progetto è l'"**Heart Failure Prediction Dataset**", reperito tramite la piattaforma Kaggle. Questo dataset è particolarmente significativo in quanto nasce dalla fusione di cinque database cardiaci indipendenti (Cleveland, Hungarian, Switzerland, Long Beach e Stalog), risultando in uno dei dataset più completi per la ricerca sulle malattie cardiovascolari.

2.1 DIMENSIONI E STRUTTURA

Il dataset è composto da un totale di **918 istanze** (pazienti) e **12 colonne**, di cui 11 variabili indipendenti (feature) e una variabile target. La struttura è di tipo tabulare e non presenta un forte dislivello tra le classi, fattore che agevola la fase di addestramento dei modelli.

2.2 DESCRIZIONE DELLE VARIABILI (FEATURE)

Le caratteristiche possono essere suddivise in tre categorie principali:


Variabili Anagrafiche e Cliniche Generali:

- **Age:** Età del paziente [anni].
- **Sex:** Sesso del paziente [M: Maschio, F: Femmina].
- **RestingBP:** Pressione sanguigna a riposo [mm Hg].
- **Cholesterol:** Colesterolo sierico [mm/dl].
- **FastingBS:** Glicemia a digiuno [1: se > 120 mg/dl, 0: altrimenti].

Variabili legate alla sintomatologia e all'ECG:

- **ChestPainType:** Tipo di dolore toracico [TA: Angina tipica, ATA: Angina atipica, NAP: Dolore non anginoso, ASY: Asintomatico].
- **RestingECG:** Risultati dell'elettrocardiogramma a riposo [Normal, ST: anomalie dell'onda ST-T, LVH: ipertrofia ventricolare sinistra].
- **MaxHR:** Frequenza cardiaca massima raggiunta [valore tra 60 e 202].
- **ExerciseAngina:** Angina indotta dall'esercizio fisico [Y: Sì, N: No].

- **Oldpeak:** Depressione del segmento ST indotta dall'esercizio rispetto al riposo.
- **ST_Slope:** La pendenza del segmento ST durante l'esercizio di picco [Up: in salita, Flat: piatto, Down: in discesa].




Variabile Target:

- **HeartDisease:** Output binario che indica la presenza (1) o l'assenza (0) di una malattia cardiaca.

2.3 DISTRIBUZIONE DELLA VARIABILE TARGET

Un'analisi preliminare ha mostrato che circa il 55% dei pazienti nel dataset presenta una malattia cardiaca. Questo leggero sbilanciamento verso la classe positiva è accettabile e riflette la natura della raccolta dati in ambito clinico, dove è più frequente analizzare soggetti che presentano già dei sintomi.



3. Issue e scelte di Progettazione

In questa sezione vengono dettagliate le problematiche riscontrate nel dataset originale e le metodologie adottate per preparare i dati alla fase di modellazione (Data Preprocessing).

3.1 GESTIONE DEI VALORI ANOMALI

Durante l'analisi esplorativa, è emersa un'anomalia significativa nella colonna Cholesterol: 172 istanze presentavano un valore pari a 0. Poiché un livello di colesterolo nullo è biologicamente impossibile in un soggetto vivente, tali valori sono stati trattati come **dati mancanti (missing values)** e quindi non considerati per il calcolo di media e mediana.

Invece di eliminare le righe (che avrebbe ridotto drasticamente il dataset), si è optato per l'**imputazione tramite mediana**. La mediana è stata preferita alla media poiché è meno sensibile agli outlier estremi presenti nei livelli di colesterolo elevati.

```
--- ANALISI VALORI COLESTEROLO ---  
Media (con zeri): 198.80  
Mediana (con zeri): 223.00  
  
Media (SENZA zeri): 244.64  
Mediana (SENZA zeri): 237.00
```

3.2 CODIFICA DELLE VARIABILI CATEGORICHE

Una sfida significativa del dataset è la presenza di numerose variabili espresse in formato testuale, che non sono direttamente elaborabili dagli algoritmi matematici di Machine Learning. Per superare questo ostacolo, è stata applicata la tecnica del **One-Hot Encoding**.

- **One-Hot Encoding:** A differenza del *Label Encoding* (che assegna un numero crescente alle categorie), il One-Hot Encoding crea una nuova colonna binaria (0 o 1) per ogni categoria presente nella variabile originale. Questa scelta è fondamentale per variabili come ChestPainType (Tipo di dolore toracico) o RestingECG, poiché queste non possiedono un ordine gerarchico naturale. L'uso di numeri progressivi (1, 2, 3) avrebbe indotto i modelli a percepire erroneamente una categoria come "maggiore" di un'altra.
- **Gestione della ridondanza:** In fase di implementazione, è stato rimosso il primo livello di ogni variabile codificata (parametro `drop_first=True`). Questa operazione è essenziale per evitare una situazione di multicollinearità perfetta dove una colonna è predicibile dalle altre. Eliminando la colonna ridondante, il modello risulta più snello e statisticamente robusto, facilitando la convergenza di algoritmi come la *Regressione Logistica*.

Prendendo ad esempio il tipo di dolore toracico, che ha 4 varianti, il One-Hot Encoding con `drop_first=True` ci ha permesso di rappresentare questa informazione con sole 3 colonne. La quarta è implicitamente rappresentata dal caso in cui le altre tre sono zero. Questo ha rimosso la dipendenza lineare tra le variabili, permettendo alla Regressione Logistica di calcolare i pesi in modo univoco e matematicamente corretto.

La modifica ha riguardato i campi: Sex, ChestPainType, RestingECG, ExerciseAngina e ST_Slope.

3.3 FEATURE SCALING

Le feature numeriche del dataset presentano range molto diversi (l'Età varia tra 28 e 77, mentre il Colesterolo arriva oltre i 600).

È stato applicato perciò lo **StandardScaler**, ovvero una tecnica che trasforma i dati affinché abbiano media 0 e deviazione standard 1.

$$z = \frac{x - \mu}{\sigma}$$

La presenza di valori negativi nei dati trasformati indica che l'istanza originale si trovava al di sotto del valore medio per quella specifica caratteristica.

Lo scaling è fondamentale per algoritmi basati sulle distanze e per quelli che utilizzano la discesa del gradiente, garantendo che nessuna variabile domini le altre solo per la sua grandezza numerica.

3.4 SUDDIVISIONE DEL DATASET

Per valutare correttamente la capacità del modello di generalizzare su pazienti mai analizzati in precedenza, è stata adottata la strategia dell'**Hold-out**. Questa tecnica consiste nel dividere il dataset originale in due sottoinsiemi separati e indipendenti:

- **Training Set (80% dei dati):** Questo insieme è stato utilizzato per "istruire" gli algoritmi. Durante questa fase, i modelli hanno analizzato le relazioni tra le caratteristiche cliniche (feature) e la presenza della malattia (target) per imparare a riconoscere i pattern diagnostici.
- **Test Set (20% dei dati):** Questo insieme è stato utilizzato solo alla fine del Training per simulare l'applicazione del modello in un contesto reale. In questo modo, le metriche ottenute riflettono le reali prestazioni del sistema su dati non noti.

Dettagli Tecnici:

1. **Dimensione del campione:** Su un totale di 918 pazienti, circa 734 sono stati usati per il training e 184 per il test.
2. **Riproducibilità:** La suddivisione è stata effettuata impostando un parametro di casualità fisso (`random_state=42`). Questo garantisce che ogni volta che il codice viene eseguito, i pazienti vengano assegnati agli stessi set, rendendo i test confrontabili e scientificamente validi.

4. Analisi delle Prestazioni

In questa sezione vengono presentati e commentati i risultati ottenuti dai tre modelli di classificazione testati: **Logistic Regression**, **Random Forest** e **Support Vector Machine**.

4.1 METRICHE DI VALUTAZIONE

Per confrontare i modelli in modo rigoroso, sono state utilizzate le quattro metriche standard che seguono.

- **Accuracy:** Indica quante diagnosi totali sono corrette. È una misura generale.
- **Precision:** Indica quanti, tra quelli che il modello ha predetto come "malati", lo sono veramente.
- **Recall:** Indica quanti, tra tutti i malati reali, il modello è riuscito a scovare. (In ambito medico, la Recall è la metrica più critica, poiché un Falso Negativo è molto più pericoloso di un Falso Positivo)
- **F1-Score:** È la media tra Precision e Recall. Si usa per capire se il modello è equilibrato.

4.2 MATRICI DI CONFUSIONE E ANALISI DEGLI ERRORI

Mentre l'accuratezza fornisce una visione d'insieme, le **Matrici di Confusione** permettono di analizzare i "tipi di errore" commessi.

- **Falsi Negativi (FN):** Rappresentano i casi più critici (pazienti malati classificati come sani). Il modello **Random Forest** ha mostrato la migliore capacità nel ridurre questo errore, ottenendo la **Recall** più elevata.
- **Falsi Positivi (FP):** Rappresentano pazienti sani classificati come malati. Sebbene meno gravi dei precedenti, comportano stress inutile per il paziente ed esami clinici superflui.

4.2.1 Logistic Regression

Dalla matrice di confusione si evince che il modello ha commesso 16 errori di tipo Falso Negativo. Questo indica che, nonostante un'ottima accuratezza, c'è ancora margine di miglioramento per rendere il sistema più sicuro in fase di screening clinico.


Accuracy: 0.8641
Precision: 0.9100
Recall: 0.8505
F1-Score: 0.8792



4.2.2 Random Forest

Il Random Forest ha mostrato una capacità superiore nel minimizzare i Falsi Negativi rispetto alla Logistic Regression, rendendolo un candidato migliore per uno strumento di screening preliminare.


Accuracy: 0.8696
Precision: 0.8879
Recall: 0.8879
F1-Score: 0.8879



4.2.3 Support Vector Machine

Sebbene la Logistic Regression abbia una Precision più alta (0.9100), la SVM la supera nella **Recall** (0.8762 vs 0.8505). In ambito medico, questo è un vantaggio: la SVM è riuscita a identificare correttamente un numero maggiore di pazienti realmente malati rispetto al modello lineare.

Accuracy: 0.8478
Precision: 0.8762
Recall: 0.8598
F1-Score: 0.8679




4.3 RISULTATI OTTENUTI

I risultati ottenuti sul Test Set sono riassunti nella tabella seguente:

Metrica	Logistic Regression	Random Forest	SVM
Accuracy	0.8641	0.8696	0.8478
Precision	0.9100	0.8879	0.8762
Recall	0.8505	0.8879	0.8598
F1-SCORE	0.8792	0.8879	0.8679


4.4 IMPORTANZA DELLE FEATURE

Per aumentare l'interpretabilità del modello Random Forest, è stata calcolata la **Feature Importance**.



I risultati mostrano che i segnali derivanti dall'ECG (Oldpeak e ST_Slope) sono più determinanti dell'età del paziente, suggerendo che il modello si sta concentrando su indicatori clinici oggettivi piuttosto che su semplici dati anagrafici.

4.5 CURVE ROC E AUC



Infine, dal confronto visivo tramite le **Curve ROC** (Receiver Operating Characteristic) si evince che nonostante il modello **SVM** faccia registrare il valore di **AUC** più elevato (a testimonianza di una superiore capacità discriminante intrinseca e di una maggiore robustezza nel separare le classi lungo l'intero spettro delle probabilità) il **Random Forest** si conferma la soluzione più efficace per l'impiego clinico pratico. Quest'ultimo, infatti, mostra una lieve superiorità nelle metriche come **Accuracy** e **Recall**, risultando più performante nell'identificazione immediata dei soggetti a rischio sulla soglia decisionale standard. In sintesi, se la SVM eccelle per qualità teorica della classificazione, il Random Forest offre il bilanciamento più affidabile per le finalità di screening.

5. Considerazioni Finali e Sviluppi Futuri

5.1 CONCLUSIONI SUL MODELLO MIGLIORE

Sulla base dell'analisi comparativa effettuata, il modello **Random Forest** è stato identificato come la soluzione più performante per questo specifico task di classificazione.

Con un'**Accuracy dell'86.96%** e, soprattutto, una **Recall dell'88.79%**, il Random Forest si dimostra lo strumento più affidabile in un contesto clinico.

L'elevata Recall è il fattore determinante: in ambito medico, minimizzare i "Falsi Negativi" è prioritario per garantire che i soggetti a rischio ricevano tempestivamente le cure necessarie. La capacità del Random Forest di gestire le relazioni non lineari tra variabili eterogenee (cliniche, anagrafiche ed elettrocardiografiche) gli ha permesso di superare sia la rigidità della Regressione Logistica che la complessità computazionale della SVM.

5.2 RIFLESSIONI SUGLI ERRORI E UTILITÀ CLINICA

Sebbene la **Regressione Logistica** abbia mostrato la **Precision più elevata (0.9100)**, la sua minor capacità di individuare tutti i casi positivi la rende meno adatta come strumento di screening primario rispetto al Random Forest. La **SVM**, d'altro canto, ha confermato l'importanza del preprocessing: pur non raggiungendo il primato in nessuna metrica, ha mantenuto prestazioni equilibrate, dimostrando che una corretta standardizzazione dei dati permette anche a modelli basati su distanze di competere efficacemente su dataset medici complessi.

5.3 SVILUPPI FUTURI

Nonostante gli ottimi risultati raggiunti, il progetto lascia spazio a ulteriori margini di miglioramento che potrebbero essere esplorati in studi successivi, tra cui:

- **Integrazione di nuovi dati:** L'aggiunta di variabili legate allo stile di vita (fumo, attività fisica settimanale, dieta) potrebbe arricchire il potere predittivo del modello.
- **Interfaccia grafica:** Pensata per la visualizzazione dei risultati e l'inserimento dei nuovi dati.